


satu tingkat keberhasilan: $p = 0.90$

dua pertanyaan yang berbeda, dua jawaban yang berlawanan



$\text{pass}@k$

ada yang berhasil?

100.0%

pass^k

semuanya berhasil?

34.9%

Angka yang sama, $p = 0.90$. Papan skor melaporkan yang hijau; pengguna mengalami yang merah.

Menaikkan k memperbaiki kemampuan dan memperburuk keandalan — dan keduanya benar sekaligus.