



Institut Teknologi Bandung

Directorate of Sustainable Professional Education

CHAPTER 4

Ingatan: yang disimpan, yang dicari lagi, yang dibuang

Model tidak mengingat apa pun. Semua yang tampak seperti ingatan adalah keputusan rekayasa — dan tiap keputusannya punya harga yang bisa dihitung.

Duration 3 jam (2 sesi)

Instructor Hendri Karisma

Source Grootendorst & Alammar, An Illustrated Guide to AI Agents — bab 4

Session Objectives

By the end of this session, participants can:

- 1 **Menyebutkan tiga lapis ingatan** dan menentukan apa yang pantas disimpan di masing-masing.
- 2 **Membandingkan memangkas dan meringkas**, dan menyebutkan kerugian yang tidak terlihat dari yang kedua.
- 3 **Menjelaskan pengambilan sebagai ALAT**, bukan sebagai langkah praproses — dan menyebutkan akibatnya pada jejak dan kutipan.
- 4 **Menyebutkan empat operasi rekayasa konteks** dan menerapkannya pada satu gelung yang terlalu panjang.
- 5 **Menyebutkan dua kelas serangan** yang muncul begitu agen menyimpan ingatan, dan penanganannya di batas alat.
- 6 **Memutuskan apa yang TIDAK boleh disimpan**, dengan alasan yang bisa dipertahankan di depan pemeriksa.

SITE

[Course home](#)

BOOK

[Maarten Grootendorst & Jay Alammar, An Illustrated Guide to AI Agents \(O'Reilly Media, Early Release\)](#)

01

Tiga lapis, dan tidak satu pun gratis


Yang tampak seperti ingatan selalu keputusan seseorang.

Yang disebut ingatan sebenarnya daftar pesan Anda

Itu berarti seluruh perilaku \{{u}201cmengingat\{{u}201d pada sistem Anda adalah **rekayasa** — apa yang dimasukkan, apa yang dibuang, dan apa yang dicari kembali. Tidak ada yang otomatis, dan tidak ada yang gratis.

Kabar baiknya: keadaan yang Anda pegang adalah keadaan yang bisa Anda **periksa, potong, uji, dan pertanggung-jawabkan**. Ingatan yang ada di dalam bobot model tidak punya satu pun dari sifat itu.

Tiga lapis, dengan umur dan harga yang berbeda



Semakin ke kanan, semakin murah disimpan dan semakin mahal diambil.

Ingatan kerja hidup satu giliran: hasil alat mentah, yang biasanya besar dan hampir seluruhnya tidak perlu dibawa ke giliran berikutnya. **Jangka pendek** adalah percakapan ini. **Jangka panjang** ada di luar konteks dan hanya masuk ketika dicari.

Pertanyaan yang memutuskan lapis mana

PERTANYAAN	KALAU YA	CONTOH
Dipakai lagi di giliran berikutnya?	Jangka pendek	Nomor rekening yang sedang dibahas
Dipakai lagi minggu depan?	Jangka panjang	Preferensi pengguna, keputusan yang pernah diambil
Hanya untuk menghasilkan satu angka?	Ingatan kerja	1 843 baris transaksi → satu rasio
Bisa dihitung ulang kapan saja?	Jangan disimpan	Apa pun yang alat bisa berikan lagi

Baris terakhir yang paling sering dilanggar. Menyimpan sesuatu yang bisa diambil ulang berarti menukar **biaya token yang pasti dengan risiko data basi**

02

Jangka pendek: memangkas atau meringkas


Dua cara, dua kerugian — dan hanya satu yang kelihatan.

Memangkas: kehilangan yang jujur

Kerugiannya juga pasti, dan itu kekuatannya: Anda tahu persis apa yang hilang. Masalahnya muncul ketika yang hilang adalah **batasan yang disebut di awal** — jangan hubungi nasabah lewat surel yang diucapkan pada giliran kedua tidak ada lagi pada giliran kedua puluh.

Bentuk kegagalannya khas dan mudah dikenali: agen bekerja benar selama sepuluh giliran, lalu mulai **melanggar aturan yang sudah tidak ada di konteksnya**. Itu bukan model yang lupa; itu jendela yang menggeser.

Meringkas: kehilangan yang tidak terlihat



Peringkasan yang diulang, dihitung pemangkastannya. Langkah: asli, dua kali pertama, lalu enam kali.

Meringkas terasa lebih baik daripada memangkas — tidak ada yang dibuang, semuanya masih ada. Tetapi peringkasan berikutnya bekerja atas **ringkasan**, bukan atas aslinya, sehingga apa pun yang hilang tiap kali dipangkatkan.

Yang paling dulu hilang dari sebuah ringkasan

Angka dan pengenalan

\({}^{201}cRasio\ 0,82\)^{201}d jadi \({}^{201}crasionya\ ren-
dah\)^{201}d. Setelah itu tidak ada cara memulihkannya, dan
tidak ada yang tahu itu terjadi.

Batasan yang bersyarat

\({}^{201}cBoleh,\ KECUALI\ kalau\ nasabahnya\ di\ bawah\ 21\)^{201}d cenderung jadi \({}^{201}cboleh\)^{201}d.

Yang belum diputuskan

Ringkasan cenderung menutup pertanyaan yang masih terbuka, sebab teks yang rapi terbaca lebih baik.


Urutan waktu

Mana yang lebih dulu sering hilang, dan itu penting justru saat menelusuri kesalahan.

Perhatikan polanya: yang hilang duluan justru yang **paling**

menentukan keputusan. Prosa yang menjelaskan bertahan; angka dan pengecualian tidak.

Bentuk campuran yang biasanya menang



Yang tetap, yang diringkas, dan yang utuh — masing-masing punya alasan.

- ① {'h': 'Perintah sistem tidak pernah diringkas', 'p': 'Ia bagian tetap, dan ia yang membuat singgahan prompt bekerja.'}
- ② {'h': 'Giliran pertama disimpan utuh', 'p': 'Di situ tujuan dan batasan disebut. Inilah yang paling sering hilang dan paling mahal hilangnya.'}
- ③ {'h': 'Bagian tengah diringkas, satu kali', 'p': 'Ringkas dari **aslinya** kalau masih ada, bukan dari ringkasan sebelumnya. Itu yang mematahkan pemangkatan di gambar tadi.'}
- ④ {'h': 'Beberapa giliran terakhir utuh', 'p': 'Di situ konteks langsung berada, dan di situ ketepatan paling terasa.'}

Simpan aslinya, ringkas dari sana

Penyimpanannya murah — teks di basis data, bukan token di konteks. Yang mahal adalah konteks, dan itu tidak bertambah.

Dengan begitu kerugiannya berhenti berlipat: ia jadi kerugian **satu kali** dari sumber lengkap, bukan kerugian berulang dari salinan yang makin tipis.

03

Jangka panjang: mengambil, bukan mengingat

Dan kenapa pengambilan itu alat, bukan langkah praproses.

Bentuk dasarnya, dan satu kalimat yang menentukan segalanya




Pertanyaan jadi vektor, dicari yang mirip, potongan teratas masuk konteks.

Mekanismenya sudah dibahas di **Bab 14** kelas ini — penyematan, kemiripan, indeks. Yang penting di sini satu kalimat: **model hanya bisa menjawab dari potongan yang terambil**. Apa pun yang tidak terambil, untuk keperluan jawaban itu, tidak ada.

Karena itu mutu sistem semacam ini hampir seluruhnya ditentukan oleh **mutu pengambilannya**, bukan oleh kepintaran modelnya — dan di situlah waktu perbaikan sebaiknya dihabiskan.

Pengambilan sebagai alat mengubah tiga hal



Agen memutuskan apa yang dicari, membaca hasilnya, dan boleh mencari lagi.

Praproses: satu pencarian, dengan kata-kata pengguna apa adanya, sebelum model melihat apa pun.

Kalau kata pengguna buruk, hasilnya buruk, dan tidak ada kesempatan kedua.

Alat: model menyusun kata pencariannya sendiri, membaca hasilnya, dan boleh mencari lagi dengan istilah berbeda.

Lebih mahal — tiap pencarian satu giliran — dan jauh lebih tahan terhadap pertanyaan yang dirumuskan buruk.

Dan yang paling penting untuk sistem yang diawasi: sebagai alat, tiap pengambilan **tercatat di jejak** — apa yang dicari, apa yang kembali, dan potongan mana yang dipakai.

Kutipan bukan hiasan; ia satu-satunya cara memeriksa

- 1 {'h': 'Kutip potongan, bukan dokumen', 'p': '\\\\u201cKebijakan kredit\\\\u201d tidak bisa diperiksa; \\\\u201cklausul CP-04, paragraf 2\\\\u201d bisa.'}
- 2 {'h': 'Periksa kutipannya dengan kode', 'p': 'Kalau pengenalan yang dikutip tidak ada di hasil pengambilan, itu karangan — dan kode Anda bisa mengetahuinya tanpa model.'}
- 3 {'h': 'Simpan potongannya di jejak', 'p': 'Agar setahun kemudian pertanyaan \\\\u201ccatas dasar apa\\\\u201d punya jawaban, bukan rekonstruksi.'}

Demo kredit UMKM melakukan persis ini: tiap rekomendasi membawa klausul yang dipakai, dicetak penuh, dan uji akan gagal kalau klausul yang dikutip tidak ada.

Apa yang pantas jadi ingatan jangka panjang

Fakta yang stabil

Preferensi, keputusan yang pernah diambil beserta alasannya, hasil yang mahal dihitung ulang.

Jangan sama sekali

Data pribadi yang tidak dibutuhkan agen, kredensial, dan apa pun yang retensinya diatur — kecuali retensi itu ikut diterapkan.

Perlu kedaluwarsa

Apa pun yang bisa berubah di sistem lain. Simpan pengenalnya, ambil ni-lainya saat dipakai.

Kartu ketiga bukan nasihat kehati-hatian umum. Ingatan adalah **basis data baru** yang sering lahir tanpa pemilik, tanpa kebijakan retensi, dan tanpa seorang pun menyadari ia sudah berisi data pribadi.

Di mana teks dipotong menentukan apa yang bisa ditemukan

potong ukuran tetap



potong dengan tumpang tindih



potong menurut struktur



satu klausa = satu potongan
Potongan ukuran tetap memotong fakta di tengah: "kategori B" ada di potongan kiri, "Rp 500 juta" di kanan.
Tak satu pun potongan bisa menjawab pertanyaan tentang batas kategori B — dan tidak ada yang melaporkan kegagalan itu.

Satu kalimat, tiga cara memotong. Langkah: ukuran tetap, tumpang tindih, lalu menurut struktur.

Pemotongan biasanya digambar sebagai deretan kotak seukuran, yang memperlihatkan mekanismenya dan menyembunyikan satu-satunya hal yang penting: **kalimat yang maknanya melintasi batas potongan hilang dari kedua sisinya.**

Memilih cara memotong, tanpa mencoba semuanya

BENTUK DOKUMEN	CARA YANG COCOK	ALASANNYA
Kebijakan, peraturan, kontrak	Menurut struktur	Klausul memang unit maknanya, dan nomornya jadi kutipan
Manual, dokumentasi	Menurut judul bagian	Satu bagian menjawab satu pertanyaan
Percakapan, tiket	Per giliran atau per pesan	Batas alaminya sudah ada
Prosa panjang tanpa struktur	Tetap + tumpang tindih	Tidak ada batas alami; tumpang tindih membeli jaminan
Tabel dan lembar kerja	Jangan dipotong sebagai teks	Jadikan alat kueri, bukan potongan untuk dicari kemiripannya

Baris terakhir yang paling sering dilanggar dan paling mahal: **tabel yang diubah jadi potongan teks kehilangan justru sifat yang membuatnya berguna**, yaitu bisa dihitung.

Kemiripan bukan relevansi

Parafrase pertanyaan

Potongan yang mengulang pertanyaan dengan kata lain skornya tinggi, isinya tidak menjawab apa pun.

Angka dan kode

Kemiripan makna buruk untuk nomor klausul, kode produk, dan pengenalan — di situ pencarian kata kunci menang telak.

Negasi

“boleh” dan “tidak boleh” sangat mirip secara vektor, dan berlawanan artinya.

Obat yang paling sering cukup: **gabungkan pencarian kata kunci dengan pencarian vektor**, lalu urutkan ulang hasil gabungannya. Ini rekayasa pencarian biasa, dan ia mengalahkan penggantian model.

Ambil banyak, saring ketat

- 1 { 'h': 'Ambil lebih banyak daripada yang akan dipakai', 'p': 'Pencarian awal murah dan tidak perlu tepat — tugasnya memastikan jawabannya **ada di dalam** kumpulan yang diambil.' }
- 2 { 'h': 'Urutkan ulang dengan model yang lebih teliti', 'p': 'Membaca pertanyaan dan potongan bersama-sama, bukan membandingkan dua vektor. Lebih mahal per potongan, dan hanya dijalankan pada yang sedikit.' }
- 3 { 'h': 'Masukkan hanya yang teratas', 'p': 'Bab 2: konteks yang penuh menurunkan ketepatan. Yang tidak masuk bukan kerugian, ia penghematan ganda.' }

Pola ini — **jaring lebar lalu saringan halus** — sama dengan deteksi objek di Bab 12: usulan banyak, lalu penyaringan. Bentuk yang sama muncul lagi karena alasan yang sama.

04

Rekayasa konteks

Empat operasi, dan konteks sebagai spesifikasi.

Empat operasi, dan itu saja

OPERASI	PERTANYAANNYA	KESALAHAN YANG BIASA
Melacak	Apa yang sudah terjadi dan di mana disimpan?	Tidak ada yang disimpan di luar konteks, jadi tidak ada yang bisa diambil ulang
Memilih	Apa yang masuk ke giliran ini?	Memasukkan semua yang muat, sebab masih ada ruang
Memampatkan	Bagaimana memperkecil tanpa kehilangan yang penting?	Meringkas ringkasan — lihat gambar tadi
Mengurutkan	Apa di awal, apa di akhir?	Menaruh aturan penting di tengah tumpukan hasil alat

Keempatnya keputusan **kode**, bukan keputusan model. Kalau tidak ada yang menuliskannya, keempatnya tetap terjadi — hanya saja secara kebetulan.

Memilih: yang muat bukan berarti pantas masuk

Jadi memilih bukan penghematan biaya semata — ia **menaikkan mutu jawaban**. Sepuluh potongan yang tepat mengalahkan seratus potongan yang mengandung sepuluh itu.

Uji yang mudah dan jarang dilakukan: jalankan kumpulan uji Anda dengan potongan yang diambil dikurangi separuh. Kalau angkanya tidak turun, **separuh konteks Anda selama ini hanya biaya**

Mengurutkan: awal dan akhir adalah tempat istimewa

Taruh di awal

- ♦ Peran dan batasan
- ♦ Definisi yang dipakai sepanjang percakapan
- ♦ Skema alat

Dan konsekuensi yang sering terlewat: menaruh pengingat

Taruh di akhir

- ♦ Permintaan giliran ini
- ♦ Hasil alat yang baru saja kembali
- ♦ Pengingat format keluaran

format di **akhir** bekerja jauh lebih baik daripada menaruhnya di perintah sistem, ketika percakapannya sudah panjang.

Konteks adalah spesifikasinya

- 1 { 'h': 'Kalau ia dirakit, ia bisa diuji', 'p': 'Rakit konteks untuk kasus uji, dan periksa isinya sebelum dikirim. Itu uji unit biasa, dan tidak butuh model.' }
- 2 { 'h': 'Kalau ia spesifikasi, ia pantas ditinjau', 'p': 'Perubahan pada penyusun konteks pantas dibaca orang lain, seperti perubahan kode.' }
- 3 { 'h': 'Kalau ia berubah tiap giliran, ia pantas dicatat', 'p': 'Jejak harus memuat konteks yang dipakai, bukan hanya jawabannya.' }

Cara paling cepat memperbaiki agen yang mengecewakan hampir selalu **memperbaiki apa yang masuk ke konteks - snya**, bukan mengganti modelnya.

Ingatan kerja: jangan biarkan hasil alat menetap

Pola yang mahal

Alat mengembalikan 1 843 baris transaksi; semuanya masuk riwayat; enam giliran berikutnya membayarnya lagi dan lagi.

Pola yang murah

Alat menghitung di sisinya sendiri dan mengembalikan rasio yang diminta. Baris mentahnya disimpan di luar konteks, dengan pengenalan, kalau-kalau perlu.

Aturan yang mudah diingat: **alat mengembalikan jawaban, bukan bahan**. Kalau agen harus menghitung sendiri dari data mentah, itu tanda pekerjaan berada di tempat yang salah.

Siapa yang memutuskan sesuatu layak diingat

SIAPA	CARA KERJANYA	PERTUKARANNYA
Aturan kode	Simpan hal yang jenisnya sudah ditentukan	Bisa diramalkan dan diuji; melewatkan yang tak terduga
Model	Agen memanggil alat "ingat ini"	Menangkap yang tak terduga; tumbuh cepat dan bisa salah
Manusia	Pengguna menandai sesuatu untuk diingat	Paling tepat, paling jarang dipakai

Yang paling sering berhasil: **kode untuk yang wajib, model untuk yang opsional, dan batas jumlah** — supaya "ingat ini" tidak berubah jadi tempat pembuangan.

Melupakan adalah fitur, bukan kekurangan

- ① {'h': 'Beri tanggal pada semuanya', 'p': 'Tanpa waktu, tidak ada cara memilih antara dua ingatan yang bertentangan.'}
- ② {'h': 'Perbarui, jangan menumpuk', 'p': 'Ingatan baru tentang hal yang sama harus **mengganti** yang lama, bukan berdiri di sebelahnya.'}
- ③ {'h': 'Kedaluwarsakan yang bisa basi', 'p': 'Apa pun yang sumbernya sistem lain punya umur. Simpan pengenalnya, ambil nilainya.'}
- ④ {'h': 'Sediakan penghapusan yang sungguhan', 'p': 'Termasuk dari indeks pencarian. Ingatan yang terhapus dari basis data tapi masih ada di indeks belum terhapus.'}

Ingatan bersama antar agen menciptakan masalah baru

Semuanya melihat semuanya

Paling sederhana, dan konteksnya membengkak paling cepat. Tiap agen membayar percakapan agen lain.

Hanya lewat pesan

Tiap agen punya konteks sendiri dan bertukar ringkasan. Lebih murah, dan kehilangan detail di tiap penyerahan.

Papan bersama

Keadaan disimpan di luar, tiap agen membaca yang perlu. Paling bisa diskalakan, paling banyak kodenya.

Perhatikan bahwa ketiganya soal **ingatan**, bukan soal kecerdasan. Sebagian besar kesulitan sistem banyak-agen ternyata kesulitan konteks.

Ingatan tidak gratis, dan ongkosnya bukan hanya token

ONGKOS	KAPAN TERASA	YANG SERING TERLEWAT
Penyematan	Saat menulis dan saat mencari	Menyematkan ulang seluruh korpus setiap ganti model penyemat
Penyimpanan	Tumbuh pelan	Indeks vektor jauh lebih besar daripada teksnya
Waktu pengambilan	Tiap giliran	Menambah satu perjalanan pulang-pergi ke tiap langkah
Token konteks	Tiap giliran sesudahnya	Potongan yang diambil dibayar ulang seperti riwayat
Kewajiban hukum	Saat diperiksa	Basis data baru berisi data orang, sering tanpa pemilik

Baris terakhir bukan ongkos teknis, dan justru itu yang paling sering tidak dianggarkan siapa pun.

Kapan tidak perlu ingatan sama sekali

Tugas satu kali yang berdiri sendiri

Menilai satu pengajuan, meringkas satu dokumen. Semua yang dibutuhkan bisa diambil dengan alat saat itu juga.

Yang bisa diambil ulang kapan saja

Kalau alat bisa memberikannya lagi, menyimpannya hanya menukar biaya pasti dengan risiko basi.

Demo kredit UMKM tidak punya ingatan lintas percakapan sama sekali, dan itu **keputusan**, bukan kelalaian: tiap penilaian berdiri sendiri, semua bahannya diambil lewat alat, dan tidak ada satu pun data nasabah yang menetap di luar sistem intinya.

Pertanyaan yang pantas ditanyakan sebelum memasang ingatan: **kegagalan mana yang sedang saya perbaiki?** Kalau tidak ada jawabannya, yang sedang dipasang adalah basis data baru tanpa alasan.

05

Ingatan sebagai permukaan serangan

Dua hal yang baru muncul begitu sistem mulai mengingat.

Perintah yang menumpang di dalam data yang dibaca



Hasil alat masuk ke konteks yang sama dengan perintah — dan terlihat sama.

Agen membaca dokumen, tiket, atau halaman. Isinya bisa memuat kalimat yang ditujukan kepada **agennya**, bukan kepada pembacanya. Selama hasil alat masuk ke konteks yang sama dengan perintah, keduanya tidak terbedakan.

Penanganannya **bukan** di prompt. Ia di batas alat: apa yang boleh dipanggil sesudah membaca sesuatu yang tidak tepercaya, dan apakah alat tulis termasuk di dalamnya.

Dan ingatan membuatnya bertahan sampai besok

- ① {'h': 'Jangan simpan teks mentah dari sumber tidak tepercaya', 'p': 'Simpan fakta yang sudah diekstrak dan divalidasi, bukan paragrafnya.'}
- ② {'h': 'Beri asal-usul pada tiap ingatan', 'p': 'Dari percakapan mana, dari dokumen mana, ditulis kapan. Tanpa itu, tidak ada cara mencabutnya.'}
- ③ {'h': 'Sediakan cara menghapus', 'p': 'Ingatan yang tidak bisa dihapus adalah kewajiban hukum yang tidak bisa dipenuhi.'}

Ingatan bersama antar pengguna adalah keputusan, bukan fitur

Per pengguna, bawaan

Ingatan diberi batas pemilik, dan pencarian selalu tersaring menurut pemiliknya — di **kode**, bukan di prompt.

Bersama, kalau memang perlu

Hanya untuk pengetahuan yang memang milik organisasi: kebijakan, prosedur, definisi. Bukan untuk apa pun yang berasal dari percakapan seseorang.

Uji yang harus lulus sebelum tayang: **buat ingatan sebagai pengguna A, lalu cari sebagai pengguna B**. Kalau kembali, sistemnya belum siap.

Data pribadi yang masuk lewat pintu belakang

- 1 {'h': 'Saring saat menulis, bukan saat membaca', 'p': 'Sekali tersimpan, ia sudah ada di cadangan dan di indeks. Penyaringan di sisi baca datang terlambat.'}
- 2 {'h': 'Simpan kategori, bukan nilainya', 'p': '"pelanggan memilih dihubungi lewat telepon" cukup; nomor teleponnya tidak perlu ada di ingatan agen.'}
- 3 {'h': 'Perlakukan ingatan sebagai sistem yang didaftarkan', 'p': 'Punya pemilik, punya kebijakan retensi, dan muncul di daftar sistem yang memproses data pribadi — atau ia tidak boleh ada.'}

Ini kelanjutan langsung dari prinsip di Bab 1: **batas kemampuan ada di kode**. Ingatan yang tidak bisa menyimpan nomor telepon lebih kuat daripada ingatan yang diminta tidak menyimpannya.

06

Mengukur dan memperbaiki

Ingatan yang tidak diukur akan membesar sampai jadi masalah.

Empat angka yang memberi tahu ingatan Anda bermasalah

ANGKA	SEHAT KALAU	GEJALA KALAU TIDAK
Token konteks per giliran	Datar	Naik terus → tidak ada yang memangkas
Potongan diambil lawan dipakai	Sebagian besar dipakai	Banyak diambil, sedikit dikutip → pengambilan terlalu longgar
Peringkasan per percakapan	Nol atau satu	Berulang → pemangkasan di gambar tadi sedang terjadi
Ingatan tersimpan per pengguna	Tumbuh pelan lalu datar	Tumbuh terus → tidak ada yang kedaluwarsa

Tidak satu pun dari empat ini menimbulkan galat. Semuanya bergeser pelan, dan gejalanya di permukaan selalu sama: **agennya terasa makin bodoh dan makin mahal.**

Mengujinya tanpa model

Uji isi konteks

Beri riwayat panjang buatan; pastikan batasan dari giliran pertama masih ada di konteks giliran ke-30.

Uji pemangkatan

Ringkas sepuluh kali; periksa apakah angka penting masih ada. Kalau hilang, arsitekturnya yang salah.

Uji batas pemilik

Simpan sebagai A, cari sebagai B, harapkan kosong. Ini uji keamanan, dan ia deterministik.

Uji kutipan

Pengenal yang dikutip harus ada di hasil pengambilan. Ini pemeriksaan kode, bukan penilaian model.

Urutan memperbaikinya, dari yang paling sering berhasil

- ① {'h': 'Perbaiki apa yang masuk sebelum menambah apa pun', 'p': 'Sebagian besar keluhan \{\}\u201cagennya lupa\{\}\u201d adalah konteks yang salah disusun, bukan ingatan yang kurang.'}
- ② {'h': 'Simpan aslinya di luar konteks', 'p': 'Ini satu perubahan yang mematahkan pemangkatan peringkasan.'}
- ③ {'h': 'Jadikan pengambilan sebagai alat', 'p': 'Sekaligus memberi Anda jejak dan kutipan — dua hal yang dibutuhkan bab 7.'}
- ④ {'h': 'Baru tambahkan ingatan jangka panjang', 'p': 'Dengan pemilik, asal-usul, dan kedaluwarsa sejak hari pertama. Menambahkannya belakangan berarti memigrasi data pribadi.'}

Perhatikan bahwa tiga langkah pertama **tidak menambah komponen baru**. Ingatan jangka panjang adalah yang terakhir dipasang, dan sering ternyata tidak diperlukan.

Yang dibawa pulang dari bab ini

- ① {'h': 'Tidak ada ingatan; yang ada keputusan rekayasa', 'p': 'Dan itu kabar baik: yang Anda susun bisa diperiksa, diuji, dan dipertanggungjawabkan.'}
- ② {'h': 'Memangkas kehilangan dengan jujur, meringkas tidak', 'p': 'Ringkasan atas ringkasan memangkatkan kerugiannya. Simpan aslinya, ringkas dari sana.'}
- ③ {'h': 'Yang tidak terambil tidak bisa dijawab', 'p': 'Mutu sistem pengambilan ada di pengambilannya, bukan di modelnya.'}
- ④ {'h': 'Konteks adalah spesifikasinya', 'p': 'Dirakit tiap giliran, jadi bisa diuji tiap giliran.'}
- ⑤ {'h': 'Ingatan adalah basis data baru', 'p': 'Dengan pemilik, retensi, dan cara menghapus — atau ia jadi kewajiban yang tidak bisa dipenuhi.'}