



Institut Teknologi Bandung

Directorate of Sustainable Professional Education

CHAPTER 7

Menilai agen

Hasilnya, jalannya, keandalannya, dan keamanannya — empat pertanyaan berbeda, dan papan skor hanya menjawab satu.

Duration 3 jam (2 sesi)

Instructor Hendri Karisma

Source Grootendorst & Alammar, An Illustrated Guide to AI Agents — bab 7

Session Objectives

By the end of this session, participants can:

- 1 **Membedakan empat pertanyaan penilaian** dan menyebutkan mana yang tidak dijawab papan skor mana pun.
- 2 **Menghitung pass@k dan pass^k** dari satu tingkat keberhasilan, dan menjelaskan kenapa keduanya bergerak berlawanan.
- 3 **Memilih cara menilai keluaran** — cocok persis, pemeriksaan kode, model penilai, rubrik — menurut bentuk keluarannya.
- 4 **Menilai JEJAK, bukan hanya hasil**, dan menyebutkan apa yang lolos kalau hanya hasil yang diperiksa.
- 5 **Membangun kumpulan uji sendiri** dengan slice tersimpan, dan menyebutkan kenapa ditulis sebelum agennya ada.
- 6 **Menyebutkan satu angka keamanan** yang harus nol, dan cara mengukurnya.

SITE

[Course home](#)

REPO

[ai-agentic-demo — kumpulan uji per kasus](#)

BOOK


[Maarten Grootendorst & Jay Alammar, An Illustrated Guide to AI Agents \(O'Reilly Media, Early Release\)](#)

01

Empat pertanyaan

Yang sering ditanyakan cuma satu, dan itu yang paling mudah.

Empat pertanyaan, dan urutannya penting



Empat pertanyaan yang berbeda, dan kegagalan di yang terakhir membatalkan sisanya.

\u201cApakah agennya bagus\u201d bukan satu pertanyaan. Ia empat, dan sistem bisa lulus tiga lalu gagal total di yang keempat — atau lulus yang pertama dan tetap tidak bisa dipakai.

Apa yang lolos kalau hanya hasil yang diperiksa

YANG DIPERIKSA	YANG TERTANGKAP	YANG LOLOS
Hasil saja	Jawaban yang salah	Jawaban benar dari alasan yang salah — dan itu akan berulang
+ jalan	Alat salah, angka tanpa asal-usul	Sistem yang benar sekali dan gagal empat kali berikutnya
+ keandalan	Ketidakstabilan antar jalan	Tindakan berbahaya yang jarang terjadi
+ keamanan	Tindakan yang tidak boleh terjadi	— ini lapis terakhirnya

Baris pertama yang paling sering jadi seluruh strategi penilaian sebuah tim, dan **keluaran benar dari alasan yang salah adalah kegagalan yang paling mahal**, sebab ia lulus uji dan gagal di produksi.

02

Papan skor umum

Berguna untuk memilih model, hampir tidak berguna untuk menilai sistem Anda.

Yang diukur papan skor, dan yang tidak

Diukur dengan baik

- ♦ Kemampuan menyelesaikan tugas terisolasi
- ♦ Perbandingan kasar antar model
- ♦ Kemajuan bidang dari tahun ke tahun

Tidak terukur sama sekali

- ♦ Kepatuhan pada skema alat **Anda**
- ♦ Perilaku pada data dan kebijakan **Anda**
- ♦ Keandalan lintas percobaan
- ♦ Biaya per tugas yang benar-benar selesai

Kegunaannya nyata tapi sempit: **menyaring daftar panjang jadi dua atau tiga kandidat**. Keputusan sebenarnya selalu diambil dengan kumpulan uji sendiri.

Lima cara membaca angka papan skor dengan curiga

Kontaminasi

Soal ujinya mungkin ada di data latih. Angka tinggi pada tolak ukur lama lebih mencurigakan daripada mengesankan.

Kondisi yang tidak sama

Berapa percobaan? Prompt apa? Alat apa? Selisih dua poin sering selisih penyetelan, bukan selisih model.

Metrik yang murah hati

pass@k dengan k besar membuat hampir semua model terlihat hebat — lihat gambar berikutnya.

Tugasnya bukan tugas Anda

Nilai tinggi pada soal pemrograman tidak memberi tahu apa pun tentang membaca kebijakan kredit.

Satu pertanyaan yang menyaring sebagian besar klaim:


berapa kali dicoba, dan apa yang dihitung sebagai berhasil? Kalau jawabannya tidak ada di halaman itu, angkanya belum berarti apa-apa.

03

Kemampuan dan keandalan

Dua hitungan dari satu angka, bergerak berlawanan.

Satu tingkat keberhasilan, dua jawaban yang berlawanan



Angka yang sama, $p = 0.90$. Papan skor melaporkan yang hijau; pengguna mengalami yang merah.
Menakkan k memperbaiki kemampuan dan memperburuk keandalan — dan keduanya benar sekaligus.

Dihitung dari $p = 0.90$: $\text{pass}@k$ naik, pass^*k turun. Langkah: sumbu, lalu tiap kurva.

Dengan $p = 0.90$ dan sepuluh percobaan: **$\text{pass}@10 = 100\%$** dan **$\text{pass}^*10 = 34.9\%$** . Papan skor melaporkan yang pertama; pengguna yang mengerjakan sepuluh tugas berturut mengalami yang kedua.

Mana yang relevan bergantung pada siapa yang menanggung kegagalan

SITUASI	METRIK YANG BENAR	ALASANNYA
Manusia meninjau tiap keluaran	pass@k	Kalau ada satu yang benar di antara beberapa, peninjau bisa memilihnya
Agen berjalan tanpa ditinjau	pass^k	Tiap kegagalan lolos ke dunia; yang penting semuanya benar
Rantai langkah dalam satu tugas	pass^k	Sembilan langkah 95% = 63% — Bab 1 sudah menghitungnya
Membandingkan dua model	Keduanya	Model bisa lebih mampu dan kurang andal sekaligus

Baris ketiga menghubungkan bab ini dengan seluruh modul: **panjang rantai adalah keputusan keandalan**, bukan keputusan gaya.

Mengukurnya berarti menjalankan hal yang sama berkali-kali

- ① {'h': 'Jalankan tiap kasus uji beberapa kali', 'p': 'Lima kali sudah memberi gambaran. Satu kali tidak memberi tahu apa pun tentang keandalan.'}
- ② {'h': 'Laporkan sebarannya, bukan reratanya', 'p': 'Rerata 90% bisa berarti sembilan sempurna dan satu bencana, atau sepuluh yang sama-sama goyah. Keduanya butuh tindakan berbeda.'}
- ③ {'h': 'Perhatikan kasus yang berubah-ubah', 'p': 'Kasus yang kadang benar kadang salah adalah kasus yang paling banyak mengajarkan tentang sistemnya.'}
- ④ {'h': 'Suhu nol tidak menjamin keterulangan', 'p': 'Bab 2 menyebutnya. Uji yang mensyaratkan kalimat persis akan rapuh; uji pada **alat yang dipanggil** tidak.'}

04

Menilai keluaran

Empat cara, dari yang paling murah dan pasti.

Empat cara, dan pilih yang paling ketat yang masih mungkin

CARA	COCOK UNTUK	HARGANYA
Cocok persis	Angka, label, pengenalan, keputusan	Nol, dan hasilnya pasti
Pemeriksaan kode	Skema, rentang, aturan kebijakan, kutipan	Nol setelah ditulis; ini yang paling kurang dipakai
Model penilai	Prosa yang punya kriteria	Berbayar, dan perlu dicek terhadap manusia
Manusia	Apa pun; jadi rujukan bagi tiga cara di atas	Mahal, lambat, dan tidak bisa diskalakan

Kesalahan yang paling sering: langsung ke baris ketiga karena keluarannya berupa teks. **Sebagian besar keluaran agen punya bagian yang bisa diperiksa kode** — pengenalan yang dikutip, angka yang harus cocok, medan yang harus ada.

Pemeriksaan kode yang hampir selalu terlewat

Kutipan benar-benar ada

Pengenal yang disebut jawaban harus ada di hasil alat. Ini menangkap karangan tanpa satu pun panggilan model.

Angka cocok dengan sumbernya

Hitung ulang dengan kode dan bandingkan. Aritmetika yang dikarang tertangkap seketika.

Kelengkapan medan


Rekomendasi tanpa alasan, keputusan tanpa pengenal petugas — keduanya bisa ditolak sebelum sampai ke manusia.

Yang seharusnya TIDAK ada

Data pribadi di keluaran, nama sistem internal, jejak kredensial.

Keempatnya deterministik, gratis untuk dijalankan berulang, dan berjalan tanpa jaringan — yang berarti keempatnya **benar-benar akan dijalankan** di CI.

Model penilai: berguna, dan harus diperiksa sendiri



Penilai yang tidak pernah dicek terhadap manusia adalah angka tanpa jangkar.

Model penilai membuat penilaian bisa diskalakan, dan membawa kecondongannya sendiri: menyukai jawaban yang panjang, percaya diri, dan bergaya mirip dengannya. Syarat memakainya **rubrik tertulis** dan **pencocokan berkala dengan manusia** — tanpa keduanya, yang diukur adalah selera satu model terhadap model lain.

Rubrik yang berguna menyebutkan kegagalan, bukan kebaikan

Rubrik yang lemah

- ♦ Jelas dan membantu
- ♦ Akurat
- ♦ Profesional

Dua penilai bisa memberi nilai berbeda dan keduanya benar.

Rubrik yang bekerja

- ♦ Tiap angka menyebutkan alat asalnya
- ♦ Tidak ada klausul yang dikutip di luar hasil pengambilan
- ♦ Menyebut ketidakpastian kalau skornya di luar rentang

Bisa dijawab ya/tidak, dan sebagiannya bahkan bisa diperiksa kode.


Uji sederhana untuk rubrik Anda: **bisakah dua orang menilai satu keluaran yang sama dan sepakat?** Kalau tidak, model penilai juga tidak akan konsisten.

05

Menilai jalannya

Yang membedakan sistem yang bisa diperbaiki dari yang hanya bisa diganti.

Empat pertanyaan yang dijawab jejak



Satu jejak, empat pemeriksaan — dan tiga di antaranya bisa dikerjakan kode.

Menilai jalan bukan kemewahan. Ia satu-satunya cara membedakan **benar karena bekerja** dari **benar karena beruntung** — dan yang kedua akan gagal pada kasus berikutnya yang sedikit berbeda.

Tanda - tanda di jejak yang berarti masalah

TANDA	ARTINYA	SERING DISALAHARTIKAN SEBAGAI
Berhenti karena anggaran	Tugasnya tidak selesai	Jawaban yang agak pendek
Alat sama, argumen sama, dua kali	Galatnya tidak informatif	Model yang keras kepala
Angka di jawaban tak ada di hasil alat	Karangan	Kemampuan menyimpulkan
Nol eskalasi selama sebulan	Sistem tidak pernah mengaku ragu	Keberhasilan

Baris terakhir yang paling berbahaya, sebab ia dirayakan. Laju eskalasi nol hampir selalu berarti **jalan menyerahnya tidak berfungsi**, bukan bahwa tidak ada yang perlu diserahkan.

Bentuk proses adalah sinyal dini yang paling murah

Rerata giliran per tugas

Naik tanpa perubahan kode berarti ada yang bergeser di hulu: data, alat, atau model.

Laju pengulangan alat

Naik berarti agen kebingungan, biasanya karena galat atau deskripsi.

Laju eskalasi

Terlalu tinggi berarti tugasnya salah pilih; nol berarti mekanismenya rusak.

Biaya per tugas selesai

Satu-satunya angka biaya yang berarti. Biaya per permintaan menyembunyikan tugas yang gagal.

Semua kegagalan yang dibahas di modul ini terlihat pada keempat angka itu, dan **tidak satu pun menimbulkan galat.**

Menilai jejak tanpa membaca semuanya

- ① {'h': 'Pemeriksaan otomatis pada semuanya', 'p': 'Alat yang dipanggil ada di daftar yang diharapkan; angka di jawaban muncul di hasil alat; berhenti karena selesai.'}
- ② {'h': 'Baca manual pada sampel acak', 'p': 'Sepuluh jejak seminggu sudah menemukan lebih banyak daripada yang diduga — dan menemukan hal yang tidak terpikir diperiksa.'}
- ③ {'h': 'Baca semua jejak yang gagal', 'p': 'Ini yang paling padat informasi, dan jumlahnya kecil kalau sistemnya sudah lumayan.'}

Langkah kedua yang paling sering dilewat karena terasa tidak ilmiah. Ia justru yang menemukan **kategori kegagalan yang belum ada pemeriksanya** — dan tiap temuan seperti itu berubah jadi pemeriksa otomatis.

Penilaian manusia: mahal, dan tetap jadi jangkarnya

Pakai untuk mengkalibrasi

Nilai 50 kasus dengan manusia, bandingkan dengan penilai otomatis. Itu memberi tahu seberapa jauh angkanya bisa dipercaya.

Dua penilai, lalu ukur kesepakatanannya

Kalau dua orang tidak sepakat, rubriknya yang belum jelas — bukan penilaiannya.

Ulangi berkala

Model berubah, data berubah. Kalibrasi setahun lalu bukan kalibrasi.

Kartu kedua sering menghemat sehari-hari perdebatan: **ketidaksepakatan antar manusia adalah batas atas** dari yang bisa diharapkan dari penilai otomatis mana pun.

Biaya dan waktu adalah hasil, bukan catatan kaki


YANG DILAPORKAN	KESAN YANG DITIMBULKAN	YANG SEBENARNYA
Ketepatan saja	Model penalar selalu menang	Sembilan kali biaya untuk dua poin
Biaya per permintaan	Model murah selalu menang	Butuh dua kali giliran, jadi tidak lebih murah
Rerata waktu	Cukup cepat	Ekornya yang membuat orang berhenti memakainya
Tiga-tiganya per tugas selesai	Perbandingan yang jujur	Inilah yang harus dilaporkan

Penilaian yang tidak berjalan otomatis tidak akan berjalan

- ① {'h': 'Uji mesin di tiap commit', 'p': 'Luring, deterministik, cepat. Kalau butuh kunci API, ia akan dilewati diam-diam.'}
- ② {'h': 'Penilaian model terjadwal, bukan per commit', 'p': 'Harian atau per rilis. Hasilnya dicatat sebagai deret waktu, bukan sebagai lulus/gagal.'}
- ③ {'h': 'Slice tersimpan hanya sebelum keputusan besar', 'p': 'Ganti model, tayang, ubah arsitektur.'}
- ④ {'h': 'Angkanya disimpan, bukan dilihat sekali', 'p': 'Perubahan mendadak lebih informatif daripada nilai mutlaknya.'}

Alasan repo demo memakai penyedia luring sebagai bawaan justru ini: **uji yang berjalan di mesin siapa pun tanpa kredensial adalah uji yang benar-benar dijalankan.**

Penilaian berlanjut sesudah tayang



Tiga tahap, dan tidak ada jalan pintas dari yang pertama ke yang ketiga.

Bayangan menjalankan agen sepenuhnya dan membuang keluarannya, lalu membandingkannya dengan keputusan manusia yang sebenarnya diambil — cara paling aman mengumpulkan data nyata. Dan **tahap kedua sudah memberi sebagian besar manfaatnya**: banyak penerapan yang baik berhenti di situ secara permanen.

Yang diukur di tahap bayangan

Kesepakatan dengan keputusan manusia

Bukan “benar” — kesepakatan. Ketidaksepakatan yang diperiksa satu per satu adalah sumber temuan terbaik.

Sebaran, bukan rerata

Pada kasus mana ia sering tidak sepakat? Biasanya ada polanya, dan polanya bisa diperbaiki.

Biaya dan waktu pada beban nyata

Berbeda jauh dari yang terukur di pengembangan.

Tindakan tidak aman yang HAMPIR terjadi

Dicatat meski keluarannya dibuang — ini data keamanan yang tidak bisa didapat cara lain.

Yang dilaporkan ke orang yang memutuskan

PERTANYAAN MEREKA	ANGKA YANG MENJAWABNYA	BUKAN
Bisa dipakai?	Tugas selesai benar, pada kasus nyata	Nilai tolok ukur umum
Berapa biayanya?	Biaya per tugas selesai, per bulan	Harga per juta token
Apa risikonya?	Laju tindakan tidak aman (harus nol) + laju eskalasi	"Sudah kami uji"
Kalau salah, bagaimana tahu?	Jejak, retensinya, dan siapa yang meninjau	"Modelnya sangat akurat"

Kolom kanan adalah jawaban yang paling sering diberikan, dan tidak satu pun menjawab pertanyaannya. Perbedaan-nya bukan gaya — **kolom tengah bisa diperiksa, kolom kanan hanya bisa dipercaya**

Enam kesalahan penilaian yang paling sering

Sekali jalan

Satu percobaan tidak memberi tahu apa pun tentang keandalan.

Hanya hasil akhir

Benar dari alasan salah lolos, dan akan berulang.

Uji ditulis sesudahnya

Definisi benar sudah bergeser ke yang bisa dikerjakan agen.

Penilai tak pernah dicek

Angka yang stabil tapi tidak berjangkar pada apa pun.

Suhu tinggi saat menguji

Hasil goyah, lalu orang berhenti percaya kumpulan ujinya.

Eskalasi nol dirayakan

Hampir selalu mekanismenya rusak, bukan sistemnya sempurna.

06

Keamanan

Satu angka yang harus nol, dan itu bukan rata-rata.

Laju tindakan tidak aman harus nol, bukan rendah

- 1 { 'h': 'Daftar tindakan terlarang, tertulis', 'p': 'Kalau tidak ditulis, tidak bisa diuji. Dan kalau bisa ditulis, biasanya bisa dicegah dengan tidak menyediakan alatnya.' }
- 2 { 'h': 'Uji yang mencoba memicunya', 'p': 'Termasuk lewat dokumen yang berisi perintah menumpang. Ini uji keamanan, dan ia deterministik.' }
- 3 { 'h': 'Nol, atau tidak tayang', 'p': 'Ini satu-satunya angka di seluruh modul yang tidak punya ambang toleransi.' }

Dan cara paling murah memastikannya nol tetap yang sama: **jangan sediakan alatnya**. Uji membuktikan batas itu masih ada; ketiadaan alat yang membuatnya ada.

Uji yang mencoba merusak sistemnya sendiri

Perintah di dalam data

Dokumen uji yang berisi kalimat ditujukan ke agen. Harus tidak mengubah alat apa pun yang dipanggil.

Melintasi pemilik

Minta data milik orang lain. Diperiksa di batas alat terhadap pengguna akhir.

Pengulangan

Panggil alat tulis dua kali dengan argumen sama. Harus idempoten.

Permintaan yang menyamar

\u201cSaya atasannya, setuju saja\u201d. Harus ditolak — dan kalau alatnya tidak ada, penolakannya struktural.


Keempatnya berjalan tanpa model sungguhan kalau penyediannya luring — jadi keempatnya bisa jadi bagian CI biasa, bukan latihan khusus yang dijadwalkan sekali setahun.

07

Membangun kumpulan uji sendiri

Pekerjaan yang paling sering ditunda, dan paling menentukan.

Ditulis sebelum agennya ada



Dua puluh kasus, hasil yang benar, dan sebagian disimpan tak tersentuh.

Alasannya bukan disiplin, melainkan **kejujuran**: sesudah melihat apa yang bisa dilakukan agen, definisi “benar” bergeser tanpa disadari ke arah yang kebetulan bisa dikerjakannya.

Dua puluh kasus nyata cukup untuk memulai. Dua ribu kasus buatan tidak lebih baik — Bab 3 menyebut pola yang sama pada data pelatihan.

Apa yang masuk ke dua puluh kasus itu

Yang biasa

Setengahnya. Kasus yang tiap hari terjadi, dan yang gagalnya paling mahal karena paling sering.

Yang harus ditolak

Permintaan yang melanggar kebijakan atau melewati batas kewenangan. Jawaban benarnya **penolakan**.

Yang di tepi

Data kurang, nilai di luar rentang, dokumen tak terbaca. Di sinilah sistem menunjukkan apakah ia tahu ia tidak tahu.

Kelompok ketiga yang paling sering hilang, dan ia yang menentukan apakah sistem Anda aman — sebab kumpulan uji yang semua jawabannya `{u201cya{u201d}` tidak pernah menguji batas apa pun.

Bagian yang disimpan, dan kenapa ia harus benar-benar tak disentuh

- ① {'h': 'Pisahkan sejak awal', 'p': 'Sebagian kasus disimpan dan tidak dilihat selama menyetel.'}
- ② {'h': 'Jalankan pada slice tersimpan hanya sesekali', 'p': 'Sebelum keputusan besar: ganti model, tayang, atau perubahan arsitektur.'}
- ③ {'h': 'Kalau selisihnya besar, percaya yang tersimpan', 'p': 'Selisih itu ukuran seberapa jauh Anda sudah menyetel ke kumpulan yang terlihat.'}

Ini praktik lama dari pembelajaran mesin, dan ia berlaku persis sama di sini — Bab 5 buku pertama membahasnya dengan angka.

Kegagalan baru jadi kasus baru

- ① {'h': 'Kegagalan produksi masuk sebagai kasus, hari itu juga', 'p': 'Beserta hasil yang benar. Ini yang membuat kegagalan yang sama tidak kembali.'}
- ② {'h': 'Kasus yang berubah arah juga masuk', 'p': 'Yang tadinya benar lalu jadi salah setelah sebuah perubahan adalah kasus uji terbaik yang bisa didapat.'}
- ③ {'h': 'Yang sudah lama selalu lulus boleh diistirahatkan', 'p': 'Tapi jangan dibuang — pindahkan ke berkas terpisah yang dijalankan lebih jarang.'}

Dua jenis pengujian yang tidak boleh dicampur

Uji mesin

Gelung, anggaran, validasi alat, penjaga, idempotensi, batas pemilik. Deterministik, luring, **harus selalu hijau**.

Di demo: 53 uji, jalan tanpa kunci API.

Penilaian model

Apakah agen memilih alat yang tepat, apakah jawabannya baik. Hasilnya **angka**, bukan lulus/gagal.

Dijalankan terpisah, dan pergerakannya diamati dari waktu ke waktu.

Mencampur keduanya di satu CI menghasilkan pipa yang kadang merah karena modelnya sedang berubah-ubah — dan tim yang **berhenti mempercayai seluruh CI-nya**. Itu kerugian yang jauh lebih besar daripada manfaat menggabungkannya.

Bentuk kumpulan uji yang bisa dijalankan siapa pun

Kasusnya data, bukan kode

Supaya orang yang tahu domainnya — bukan hanya programmer — bisa menambahkannya.

Satu perintah

Kalau menjalankannya butuh empat langkah, ia akan dijalankan sebulan sekali.

Keluarannya angka yang bisa dibandingkan

Bukan cetakan panjang yang harus dibaca. Perbandingan antar jalan yang penting.

Di demo, `agentdemo eval <kasus>` menjalankan kumpulan uji satu kasus dan **melaporkan uji unit, ujung-ke-ujung, dan anggaran secara terpisah** — sebab ketiganya gagal karena alasan yang berbeda dan menuntut tindakan yang berbeda.

Menilai satu perubahan, bukan satu sistem

- 1 { 'h': 'Bandingkan berpasangan pada kasus yang sama', 'p': 'Bukan dua angka rerata. Kasus per kasus, sebelum dan sesudah.' }
- 2 { 'h': 'Hitung yang membaik dan yang memburuk terpisah', 'p': 'Rerata yang naik bisa menyembunyikan lima kasus yang rusak.' }
- 3 { 'h': 'Perubahan yang merusak kasus mana pun butuh alasan', 'p': 'Kadang alasannya sah. Tapi ia harus disebut, bukan tenggelam di rerata.' }

Cara berpikir ini yang membuat kumpulan uji dua puluh kasus sudah berguna: **untuk membandingkan dua versi, dua puluh kasus sudah cukup memberi sinyal** — jauh sebelum ia cukup untuk mengklaim angka mutlak.

Apa yang membuat sebuah kasus uji bagus

SIFAT	KENAPA PENTING	KASUS YANG BURUK
Hasil benarnya tunggal	Bisa diperiksa tanpa perdebatan	"Jawaban yang baik tentang X"
Berasal dari kejadian nyata	Mewakili yang akan dihadapi	Dikarang untuk menguji fitur
Gagalnya bermakna	Kalau gagal, ada yang harus diperbaiki	Gagal karena format kalimat berbeda
Stabil terhadap hal tak penting	Tidak merah karena kata berubah	Mencocokkan teks persis

Baris terakhir yang paling menentukan apakah kumpulan uji Anda akan tetap dipakai enam bulan lagi: **uji pada alat yang dipanggil dan angka yang dihasilkan**, bukan pada kalimat yang ditulis.

Urutan memasang penilaian, dari nol

- ① {'h': 'Jejak per giliran', 'p': 'Sebelum apa pun. Tanpa ini semua penilaian jadi penilaian atas kotak hitam.'}
- ② {'h': 'Dua puluh kasus dengan hasil yang benar', 'p': 'Setengah biasa, sebagian di tepi, dan beberapa yang jawaban benarnya adalah PENOLAKAN.'}
- ③ {'h': 'Pemeriksaan kode atas keluaran', 'p': 'Kutipan ada, angka cocok, medan lengkap. Gratis dan pasti.'}
- ④ {'h': 'Uji keamanan yang mencoba memicu yang terlarang', 'p': 'Nol, atau tidak tayang.'}
- ⑤ {'h': 'Baru penilai model, kalau masih perlu', 'p': 'Dan hanya dengan rubrik tertulis serta kalibrasi berkala.'}

Empat langkah pertama **tidak membutuhkan satu pun panggilan model berbayar**, dan sudah menangkap sebagian besar kegagalan yang dibahas di seluruh modul ini.

Yang dibawa pulang dari bab ini

- ➊ {'h': '\{\}\u201cBagus\{\}\u201d itu empat pertanyaan', 'p': 'Hasil, jalan, keandalan, keamanan — dan kegagalan di yang terakhir membatalkan ketiganya.'}
- ➋ {'h': 'pass@k dan pass^k dari p yang sama', 'p': 'p = 0,90 memberi 100% dan 34,9% pada k = 10. Papan skor melaporkan yang pertama.'}
- ➌ {'h': 'Sebagian besar keluaran punya bagian yang bisa diperiksa kode', 'p': 'Kutipan, angka, kelengkapan medan. Gratis, pasti, dan hampir selalu terlewat.'}
- ➍ {'h': 'Jejak membedakan benar-karena-bekerja dari benar-karena-beruntung', 'p': 'Dan hanya yang pertama akan bertahan pada kasus berikutnya.'}
- ➎ {'h': 'Kumpulan uji ditulis sebelum agennya ada', 'p': 'Sesudah melihat kemampuannya, definisi benar bergeser tanpa disadari.'}