



Institut Teknologi Bandung

Directorate of Sustainable Professional Education

CHAPTER 9

Masukan yang bukan teks

Gambar, layar, dan suara — apa yang berubah pada biaya, pada apa yang bisa jadi bukti, dan pada kewajiban yang menyertainya.

Duration 3 jam (2 sesi)

Instructor Hendri Karisma

Source Grootendorst & Alammari, An Illustrated Guide to AI Agents — bab 9

Session Objectives

By the end of this session, participants can:

- 1 **Menghitung biaya token sebuah gambar** dan menjelaskan kenapa ia tumbuh menurut luas.
- 2 **Menyebutkan tiga cara modalitas disambungkan** dan pertukarannya.
- 3 **Merancang alur dokumen** yang menalar atas data terstruktur, bukan atas piksel — dan menyebutkan alasannya.
- 4 **Menyebutkan apa yang bisa dan tidak bisa diandalkan** dari model penglihatan pada dokumen nyata.
- 5 **Menjelaskan kenapa foto dokumen adalah data pribadi**, dan apa yang berubah pada rancangan karenanya.
- 6 **Menyebutkan bentuk bukti** yang membuat jawaban dari gambar bisa diperiksa manusia.

SITE

[Course home](#)

BOOK

[Maarten Grootendorst & Jay Alammar, An Illustrated Guide to AI Agents \(O'Reilly Media, Early Release\)](#)

01

Apa yang sebenarnya berubah

Gelungnya sama. Yang berubah biayanya, buktinya, dan kewajibannya.

Gelungnya tidak berubah sama sekali

Biayanya berubah

Satu gambar bisa berharga ribuan token, dan ia masuk riwayat — jadi dibayar ulang tiap giliran.

Kewajibannya berubah


Foto dokumen hampir selalu data pribadi, dan sering data yang diatur khusus.

Buktinya berubah

Saya membaca itu di gambar — tidak bisa diperiksa seperti hasil alat yang punya pengenalan.

Ketiganya keputusan rekayasa, dan ketiganya diambil sebelum satu baris kode ditulis. Kedalaman arsitektur penglihatannya ada di **Bab 8–12** kelas ini.

Cara sebuah gambar sampai ke model bahasa



Gambar jadi vektor, disamakan ruangnya dengan teks, lalu diperlakukan sebagai token.

Gambar dipecah jadi petak, tiap petak jadi vektor lewat penyandi penglihatan, lalu sebuah **penyambung** memetakan vektor itu ke ruang yang sama dengan token teks. Setelah titik itu, model bahasa memperlakukan keduanya sama.


Akibat praktis yang paling penting dari kalimat terakhir: **gambar menempati ruang jendela konteks yang sama dengan teks**, dan bersaing dengannya.

02

Biayanya

Satu gambar bukan satu lampiran.

Berapa token satu gambar



Halaman yang difoto berharga 3.3x halaman yang sama sebagai teks — dan lebih sulit dibaca modelnya.
Biaya tumbuh menurut LUAS: resolusi dua kali lipat berarti empat kali token.

Dihitung dari asumsi ubin yang tercetak di gambarnya. Langkahnya menurut ukuran gambar.

Satu foto dokumen berharga sekitar **3,3x halaman teks yang sama isinya** — dan lebih sulit dibaca modelnya. Itu dua kerugian sekaligus, dan keduanya bisa dihindari kalau teksnya memang tersedia.

Gambar masuk riwayat, dan riwayat dibayar ulang

- 1 { 'h': 'Keluarkan gambar dari riwayat begitu diekstrak', 'p': 'Simpan hasil ekstraksinya — beberapa puluh token — dan buang pikselnya dari konteks.' }
- 2 { 'h': 'Turunkan resolusi ke yang benar-benar perlu', 'p': 'Empat kali token untuk resolusi dua kali lipat. Sebagian besar tugas tidak butuh resolusi penuh.' }
- 3 { 'h': 'Potong ke bagian yang relevan', 'p': 'Satu kotak tanda tangan tidak butuh seluruh halaman.' }

Langkah pertama sendirian sering memotong biaya alur dokumen **berkali lipat**, dan hampir tidak pernah dilakukan sebab gambar terasa seperti lampiran, bukan seperti token.

03

Cara modalitas disambungkan

Tiga pendekatan, dan pertukaran yang terasa di pemakaian.

Tiga cara, dari yang paling sederhana



Proyeksi, berbasis kueri, dan peleburan.

Ketiganya menyelesaikan masalah yang sama — membuat vektor gambar bisa dibaca model bahasa — dan berbeda pada **berapa token yang dihasilkan** dan **apa yang hilang**.

...dan pertukaran yang terasa di pemakaian

CARA	TOKEN GAMBAR	PERTUKARANNYA
Proyeksi	Banyak, sebanding luas	Paling sederhana dan paling banyak dipakai; detail terjaga, biaya tinggi
Berbasis kueri	Tetap	Biaya bisa diramalkan; detail halus bisa terlewat karena jumlah tokennya tidak ikut naik
Peleburan	Bervariasi	Paling kuat pada tugas yang menuntut penalaran gabungan; paling mahal dilatih

Untuk pembangun agen, baris kedua yang paling terasa: **biaya yang bisa diramalkan** kadang lebih berharga daripada ketepatan sedikit lebih tinggi.

Suara dan video: bentuk masalah yang sama

Suara

Disandikan jadi vektor lalu disambungkan dengan cara yang sama. Untuk hampir semua agen bisnis, jalur yang benar tetap: **transkripsikan dengan alat**, lalu bekerja atas teksnya.

Video

Bingkai demi bingkai, jadi biayanya berlipat dengan durasi. Sampel beberapa bingkai kunci hampir selalu cukup, dan selisih biayanya besar.

representasi yang lebih kecil dan lebih bisa diperiksa dengan alat, lalu nalarkan atas representasi itu.

Pola yang sama muncul pada ketiga modalitas: **ubah jadi**

Dan satu keuntungan yang jarang disebut: transkrip dan data terstruktur **bisa disimpan, dicari, dan dikutip**. Piksel dan gelombang tidak.

Kenapa penyandi gambar dan teks bisa bertemu sama sekali

Jawabannya pelatihan berpasangan. Kalau banyak sekali pasangan gambar dan keterangannya dilatihkan bersama, dengan tujuan **mendekatkan pasangan yang cocok dan menjauhkan yang tidak**, kedua penyandi lama-lama menaruh “seekor kucing” dan gambar kucing di tempat yang berdekatan.

Akibat yang penting bagi pemakai: kemampuan itu **sekuat data pasangannya**. Jenis dokumen yang jarang muncul di internet — formulir bank Indonesia, misalnya — jauh lebih lemah daripada foto sehari-hari, dan itu bukan sesuatu yang bisa diperbaiki dengan prompt.

Petak, dan kenapa detail kecil hilang

Akibatnya

- ♦ Angka kecil pada tabel padat sering salah baca
- ♦ Menaikkan resolusi benar-benar menolong — dan berlipat empat biayanya
- ♦ Memotong bagian yang relevan sering lebih baik daripada menaikkan resolusi seluruh halaman

Yang bisa dilakukan

- ♦ Deteksi wilayah dulu, lalu potong dan perbesar
- ♦ Untuk tabel: alat khusus, bukan model umum
- ♦ Untuk teks: OCR sungguhan mengalahkan model bahasa

Nasihat yang menghemat paling banyak waktu di alur dokumen: **pakai alat yang memang dibuat untuk itu**. Model bahasa yang melihat gambar bukan pengganti OCR.

Tangkapan layar: modalitas yang paling cepat tumbuh

Kenapa menggoda

Sistem lama tanpa API tiba-tiba bisa diotomatiskan tanpa menunggu tim yang memeliharanya.

Kenapa rapuh

Antarmuka berubah dan agennya rusak diam-diam. Tidak ada kontrak apa pun yang menjaganya.

Dan biayanya besar: tiap langkah butuh satu tangkapan layar

baru, jadi **satu tugas sepuluh langkah berarti sepuluh gambar** di dalam satu percakapan yang sama.

Urutan yang benar hampir selalu: **cari API-nya dulu, cari basis datanya, baru pertimbangkan layar**. Yang terakhir adalah pilihan ketika tidak ada pilihan lain.

Kalau memang harus lewat layar


- 1 {'h': 'Batasi ke satu aplikasi, satu lingkungan', 'p': 'Agen yang bisa mengeklik apa saja di mesin mana saja adalah permukaan yang tidak bisa dijelaskan ke siapa pun.'}
- 2 {'h': 'Alat berupa aksi bernama, bukan "klik di 300,450"', 'p': 'buka_tagihan(id) bisa diuji dan bertahan; koordinat piksel rusak pada perubahan tata letak pertama.'}
- 3 {'h': 'Tangkapan layar terakhir saja di konteks', 'p': 'Sepuluh tangkapan layar di riwayat adalah puluhan ribu token yang dibayar berulang.'}
- 4 {'h': 'Selalu di balik persetujuan untuk tindakan yang menulis', 'p': 'Sama seperti alat tulis mana pun. Klik yang mengirim uang tetap klik yang mengirim uang.'}

04

Bentuk yang bekerja di dunia nyata

Alat dulu, penalaran belakangan.

Ekstrak dulu, nalarkan kemudian



Jalan yang lurus dan rapuh digambar sebagai garis putus.

Bab 3 sudah menyebut kesimpulannya: penalaran berlangkah di atas gambar masih jauh lebih lemah daripada di atas teks. Jadi jangan minta satu panggilan mengerjakan keduanya.

Bentuk yang bertahan: **alat mengubah gambar jadi data terstruktur; agen menalar atas data itu.** Hasilnya lebih murah, lebih tepat, dan — yang paling penting — bisa diperiksa.

Apa yang bisa dan tidak bisa diandalkan

Cukup andal

Menjelaskan isi gambar, membaca teks tercetak yang jelas, mengenali jenis dokumen, menemukan bagian yang diminta.

Sering meleset

Membaca angka pada tabel padat, mencocokkan nilai dengan kolomnya, tulisan tangan, stempel yang menimpa teks.

Jangan diandalkan

Menghitung jumlah benda, membandingkan posisi, dan aritmetika atas angka yang dibacanya sendiri.

Serahkan ke kode

Semua aritmetika. Model membaca angkanya; kode yang menghitungnya.

Kartu ketiga penting untuk dokumen keuangan: model yang membaca dua belas angka dengan benar lalu menjumlahkannya **tetap bisa salah pada jumlahnya** — dan jumlah itu yang dipakai orang.

Ekstraksi yang bisa dipercaya menyebut keyakinannya

- ① {'h': 'Kembalikan nilai beserta lokasinya', 'p': 'Kotak koordinat tempat nilai itu terbaca. Ini yang membuat manusia bisa memeriksa dalam dua detik.'}
- ② {'h': 'Bedakan kosong dari tidak terbaca', 'p': 'Medan yang memang kosong dan medan yang gagal dibaca menuntut tindakan yang berbeda sepenuhnya.'}
- ③ {'h': 'Sediakan ambang untuk minta bantuan', 'p': 'Di bawah ambang, eskalasikan — jangan menebak. Bab 5: alat menyerah dengan alasan adalah hasil yang sah.'}
- ④ {'h': 'Simpan gambarnya, bukan di konteks', 'p': 'Di penyimpanan yang punya pemilik dan retensi, dengan pengenal yang bisa dirujuk jejak.'}

Tabel adalah kasus tersulit, dan yang paling sering dibutuhkan

Kesalahan pergeseran

Nilai benar, kolomnya salah. Ini yang paling berbahaya, sebab hasilnya masuk akal dan salah.

Sel gabungan

Judul yang membentang dua kolom, atau baris yang bersambung ke halaman berikutnya.

Tabel lintas halaman

Judul kolomnya ada di halaman sebelumnya, dan tiap halaman diproses terpisah.

Karena itu untuk tabel keuangan, **alat khusus pengurai tabel mengalahkan model umum** — dan kalau tidak ada, minta model mengembalikan nilai **beserta nama baris dan kolomnya**, supaya pergeseran bisa ditangkap kode.

Tulisan tangan, tanda tangan, dan stempel

Tulisan tangan

Jauh lebih lemah daripada teks tercetak, dan lebih lemah lagi untuk angka. Untuk nilai yang menentukan keputusan, ini bukan jalur yang bisa dipercaya tanpa pemeriksaan manusia.

Tanda tangan dan stempel

Mendeteksi **keberadaannya** masuk akal dan berguna. Menilai **keasliannya** adalah tugas yang berbeda sepenuhnya, dan bukan tugas model bahasa.

Perbedaan di kolom kanan pantas ditulis di dokumen rancangan: "ada tanda tangan di kotak itu" adalah temuan yang berguna; **"tanda tangannya sah" adalah klaim yang tidak boleh dibuat sistem ini**

Dokumen banyak halaman: satu keputusan yang menentukan biaya

- 1 {'h': 'Klasifikasikan halaman dulu, dengan model kecil atau aturan', 'p': 'Halaman mana yang memuat neraca, mana yang lampiran. Murah, sekali, dan memotong sebagian besar biaya.'}
- 2 {'h': 'Proses halaman yang relevan saja, dengan resolusi penuh', 'p': 'Anggaran resolusi dibelanjakan di tempat yang benar.'}
- 3 {'h': 'Simpan pemetaannya', 'p': 'Nilai ini dari halaman 7 kotak sekian — itu kutipan yang bisa diperiksa.'}

Pola yang sama seperti pengambilan di Bab 4: **jaring lebar dengan yang murah, saringan halus dengan yang mahal.** Bentuk yang muncul lagi karena alasan yang sama.

Membandingkan dua pendekatan ekstraksi dengan angka

PENDEKATAN	KUAT PADA	LEMAH PADA
OCR + aturan	Format tetap, volume besar, biaya nyaris nol	Variasi tata letak; tiap format baru butuh kerja
OCR + model bahasa	Tata letak bervariasi, medan yang bernama	Biaya per dokumen; tetap perlu validasi
Model penglihatan langsung	Dokumen yang tak terstruktur	Paling mahal, paling sulit diaudit, paling sering salah pada tabel
Campuran	Kenyataan di kebanyakan sistem	Perlu memutuskan mana yang dipakai kapan


Keputusannya tidak perlu ditebak: **jalankan ketiganya pada dua puluh dokumen nyata** dan bandingkan ketepatan, biaya, dan laju eskalasi. Satu hari kerja, dan jawabannya tidak perlu diperdebatkan lagi.

05

Bukti dan kewajiban

Dua hal yang berubah paling besar, dan paling sering terlambat dipikirkan.

Jawaban dari gambar harus bisa ditunjuk



Satu pertanyaan yang memisahkan yang bisa diaudit dari yang tidak.

Untuk teks, kutipan berarti pengenalan potongan yang bisa diperiksa. Untuk gambar, bentuknya **lokasi** — halaman, kotak, dan nilai yang terbaca di situ. Tanpa itu, satu-satunya cara memeriksa adalah membuka dokumennya dan mencari sendiri — **agennya tidak menghemat pekerjaan siapa pun**

Foto dokumen hampir selalu data pribadi

- 1 { 'h': 'Gambar tidak keluar perimeter', 'p': 'Di demo, foto dari ponsel masuk ke penyimpanan bank dan berhenti di situ. **Tidak ada jalur kode** yang bisa mengirimnya ke penyedia model.' }
- 2 { 'h': 'Kalau harus diproses model, batasi apa yang dikirim', 'p': 'Potongan yang relevan, bukan halaman penuh. Yang tidak dikirim tidak perlu dijelaskan.' }
- 3 { 'h': 'Retensinya mengikuti dokumennya', 'p': 'Bukan mengikuti umur log. Ini yang paling sering salah.' }

Pertanyaan yang akan diajukan pemeriksa, dan yang harus dijawab dengan **jalur kode**, bukan dengan kebijakan: *ke mana perginya foto dokumen nasabah?*

Gambar juga bisa membawa perintah

Bentuk seranganya

Sebuah dokumen yang memuat kalimat ditujukan kepada agen, dicetak kecil atau ditempel di sudut halaman.

Penanganannya sama

Bukan di prompt. Di batas alat: apa yang boleh dipanggil sesudah membaca sesuatu yang tidak tepercaya.

Dan satu tambahan khas gambar: kalau dokumennya berasal dari luar, **perlakukan hasil ekstraksinya sebagai masukan tidak tepercaya** — divalidasi, bukan diteruskan apa adanya.

05b

Modalitas lain

Suara, video, dan pola yang sama muncul lagi.

Satu ruang, banyak pintu masuk



Tiap modalitas punya penyandinya sendiri, semuanya bermuara ke satu ruang.

Bentuknya seragam: tiap modalitas punya penyandi yang mengubahnya jadi vektor, lalu semuanya dipetakan ke ruang yang sama supaya model bahasa bisa memperlakukannya sebagai token.

Karena bentuknya seragam, **pertanyaan rekayasanya juga seragam**: berapa token yang dihasilkan, apa yang hilang saat penyandian, dan apakah hasilnya bisa dikutip.

Suara: hampir selalu transkripsikan dulu

Bisa disimpan dan dicari

Transkrip masuk basis data, bisa dicari, bisa dikutip. Gelombang suara tidak.

Jauh lebih murah

Satu jam rapat sebagai teks adalah beberapa ribu token; sebagai suara jauh lebih besar.

Yang hilang

Nada, keraguan, siapa berbicara. Kalau itu penting, catat sebagai meta-data — jangan bawa gelombangnya.

Dan satu kewajiban yang sering terlewat: **rekaman suara orang adalah data pribadi**, dan di banyak konteks perlu izin yang berbeda dari izin memproses teksnya.

Video: biaya berlipat dengan durasi, dan hampir selalu bisa dihindari

- ① {'h': 'Ambil bingkai kunci, bukan semuanya', 'p': 'Saat berubah, saat ada gerakan, atau satu per beberapa detik. Sering satu bingkai per adegan sudah cukup.'}
- ② {'h': 'Pisahkan suaranya dan transkripsikan', 'p': 'Untuk sebagian besar video, transkrip menjawab lebih banyak pertanyaan daripada bingkainya, dengan biaya jauh lebih kecil.'}
- ③ {'h': 'Simpan penanda waktu', 'p': 'Supaya jawabannya bisa menunjuk detik keberapa — kutipan, dalam bentuk waktu.'}

Apa yang hilang di tiap penyandian

MODALITAS	YANG BERTAHAN	YANG HILANG
Gambar	Isi, tata letak kasar, teks besar	Angka kecil, hubungan baris-kolom, detail di bawah ukuran petak
Suara	Kata-kata	Nada, keraguan, siapa berbicara — kecuali dicatat terpisah
Video	Isi bingkai yang diambil	Semua yang terjadi di antara bingkai yang diambil
Tabel sebagai gambar	Angkanya	Hubungan angka dengan kolomnya — dan itu yang dipakai

Baris terakhir yang paling sering menyebabkan kesalahan yang tidak terlihat: nilainya benar, kolomnya salah, dan hasilnya tetap terlihat masuk akal.

Apa yang boleh disimpan dari sebuah dokumen

YANG DIEKSTRAK	SIMPAN?	ALASANNYA
Angka yang dipakai keputusan	Ya	Beserta lokasinya — ini bukti yang dibutuhkan pemeriksa
Jenis dan tanggal dokumen	Ya	Metadata, dan diperlukan untuk retensi
Nama, alamat, nomor identitas	Tidak	Agen tidak membutuhkannya; petugas melihatnya di sistem inti
Gambar aslinya	Di penyimpanan dokumen	Dengan pemilik dan retensi dokumen, bukan retensi log

Baris ketiga adalah keputusan rancangan, bukan pembatasan yang merepotkan: **yang tidak disimpan tidak perlu dijaga, tidak perlu dihapus, dan tidak bisa bocor.**

06

Praktik

Merancang, mengukur, dan menguji alur yang menerima gambar.

Urutan merancang alur dokumen

- ① {'h': 'Cari tahu apakah teksnya sudah ada', 'p': 'PDF digital, hasil sistem lain, berkas asal. Kalau ada, seluruh bab ini bisa dilewati.'}
- ② {'h': 'Tulis alat ekstraksi, bukan prompt ekstraksi', 'p': 'Keluarannya berskema, dengan lokasi dan tingkat keyakinan.'}
- ③ {'h': 'Nalarkan atas data terstrukturnya', 'p': 'Di situ semua yang dipelajari tujuh bab sebelumnya berlaku seperti biasa.'}
- ④ {'h': 'Simpan gambarnya di luar konteks', 'p': 'Dengan pengenalan, pemilik, dan retensi.'}

Langkah pertama yang paling sering dilewat, dan paling sering menghapus seluruh masalah: **banyak dokumen yang difoto sebenarnya tersedia dalam bentuk teks di sistem lain.**

Mengujinya: sebagian besar tidak butuh model

Uji skema ekstraksi

Medan yang wajib ada, tipe yang benar, lokasi yang masuk akal. Kode biasa.

Kasus yang buruk sengaja

Miring, gelap, terpotong, stempel menimpa. Di sinilah sistem menunjukkan apakah ia tahu ia tidak tahu.

Kumpulan gambar tetap

Dua puluh dokumen nyata dengan nilai yang benar sudah dicatat. Ini kumpulan uji Bab 7, dalam bentuk gambar.

Uji jalur data

Pastikan tidak ada jalur kode dari penyimpanan gambar ke penyedia model. Uji struktural, seperti Bab 5.

Angka yang pantas dipantau pada alur bergambar

ANGKA	SEHAT KALAU	GEJALA KALAU TIDAK
Token gambar per tugas	Datar dan kecil	Naik → gambar tidak dikeluarkan dari riwayat
Laju ekstraksi gagal	Stabil	Naik → mutu foto turun, atau jenis dokumen berubah
Laju eskalasi karena tak terbaca	Ada, dan kecil	Nol → ambang keyakinannya tidak berfungsi
Selisih nilai terbaca lawan sistem	Mendekati nol	Ada → ekstraksinya salah, atau dokumennya bukan yang dikira

Baris ketiga sekali lagi: **nol eskalasi bukan keberhasilan**. Dokumen yang buruk pasti ada; sistem yang tidak pernah mengeluh sedang menebak.

Waktu tunggu pada alur bergambar

Perkecil sebelum dikirim

Di sisi ponsel, bukan di peladen. Resolusi yang cukup untuk dibaca sering jauh di bawah resolusi kamera.

Kerjakan yang lain sambil menunggu

Ekstraksi dokumen tidak menghalangi pengambilan data lain — itu langkah yang boleh sejajar.

Dan satu hal yang lebih besar pengaruhnya daripada keduanya: **tunjukkan apa yang sedang terjadi**. Layar yang menyebut “membaca halaman 3 dari 5” mengubah pengalaman menunggu lebih banyak daripada penghematan satu detik.

Enam kegagalan khas alur bergambar

Gambar menetap di riwayat

Dibayar ulang tiap giliran. Penyebab pembengkakan biaya nomor satu di alur dokumen.

Model menghitung sendiri

Membaca dua belas angka dengan benar lalu salah menjumlahkannya.

Nilai bergeser kolom

Masuk akal, dan salah. Tidak ter-tangkap tanpa nama baris dan kolom.

Tak terbaca dianggap kosong

Medan gagal dibaca diperlakukan seperti medan yang memang kosong.

Gambar keluar perimeter

Dikirim ke penyedia model karena tidak ada yang melarangnya di kode.

Resolusi penuh untuk semuanya

Empat kali biaya untuk ketepatan yang sering tidak berubah.

Kapan multi-modal adalah alat yang salah

Pakai alat lain

- ♦ Teksnya sudah ada di sistem lain
- ♦ Formatnya tetap dan volumenya besar → OCR + aturan
- ♦ Yang dibutuhkan hitungan → kode, selalu
- ♦ Keasliannya yang dipertanyakan → bukan tugas model bahasa

Di sinilah ia menang

- ♦ Tata letak bervariasi dan medannya bernama
- ♦ Dokumen yang tidak terstruktur
- ♦ Menentukan jenis dokumen sebelum diproses
- ♦ Menjelaskan isi gambar kepada manusia

Kolom kiri baris pertama tetap yang paling sering benar dan paling sering terlewat: **tanyakan dulu apakah dokumen itu pernah ada dalam bentuk teks** sebelum membangun apa pun.

Yang dipakai demo, dan apa yang sengaja tidak ada di sana

- 1 {'h': 'Foto pergi ke penyimpanan bank, dan berhenti di situ', 'p': 'Tidak ada jalur kode dari penyimpanan itu ke penyedia model mana pun.'}
- 2 {'h': 'Agen menerima pengenalan pengajuan, bukan gambar', 'p': 'Alat yang dimilikinya tidak mengembalikan gambar, jadi ia tidak bisa meneruskannya ke mana pun.'}
- 3 {'h': 'Klaimnya diuji, bukan dijanjikan', 'p': '`test_the_agents_tools_cannot_reach_personal_data` gagal kalau seseorang menambahkan alat yang melanggarnya.'}

Ini penerapan langsung prinsip Bab 1 pada modalitas baru: **batas kemampuan ada di ketiadaan alat**, dan ketiadaan itu bisa diuji.

Urutan memasangnya, dari yang paling murah

- 1 {'h': 'Cari teksnya', 'p': 'Kalau ada, selesai. Ini langkah yang paling sering menghapus seluruh pekerjaan.'}
- 2 {'h': 'OCR sungguhan untuk teks tercetak', 'p': 'Lebih murah dan lebih tepat daripada model bahasa untuk pekerjaan ini.'}
- 3 {'h': 'Model penglihatan untuk yang tata letaknya bervariasi', 'p': 'Dengan keluaran berskema, lokasi, dan tingkat keyakinan.'}
- 4 {'h': 'Manusia untuk yang di bawah ambang', 'p': 'Dan hitung berapa sering itu terjadi — angka itu memberi tahu apakah alurnya layak dipakai.'}

Perhatikan bahwa dua langkah pertama tidak melibatkan model bahasa sama sekali, dan keduanya menyelesaikan sebagian besar dokumen yang benar-benar dihadapi bank.

Yang dibawa pulang dari bab ini

- ① {'h': 'Gelungnya sama; biaya, bukti, dan kewajibannya berubah', 'p': 'Tidak ada mekanisme baru — hanya tiga hal yang jadi jauh lebih besar.'}
- ② {'h': 'Satu gambar bukan satu lampiran', 'p': 'Foto dokumen $\approx 3,3 \times$ halaman teks yang sama, dan biayanya tumbuh menurut luas.'}
- ③ {'h': 'Ekstrak dengan alat, nalarkan atas datanya', 'p': 'Lebih murah, lebih tepat, dan satu-satunya bentuk yang bisa diperiksa.'}
- ④ {'h': 'Jawaban dari gambar harus bisa ditunjuk', 'p': 'Halaman, kotak, nilai. Tanpa itu tidak ada yang bisa diaudit.'}
- ⑤ {'h': 'Foto dokumen adalah data pribadi', 'p': 'Dan pertanyaan "{}{}u201cke mana perginya{}{}u201d harus dijawab dengan jalur kode.'}